D Decifrando Dados

EDIÇÃO 31

Por **Marlon Ferreira**

12/10/2026 • Leitura: 4 min

Meta chega atrasada na festa da IA e traz 'open source' como desculpa

Llama 4 tenta competir com GPT-5 e Claude 4, mas a estratégia da Zuckerberg cheira a pânico tardio disfarçado de generosidade

Há 15 anos na tecnologia, o Facebook comprava o Instagram por US$ 1 bilhão e todo mundo achava que era loucura. Hoje, a Meta gasta US$ 40 bi por ano em GPUs para lançar um modelo que roda no seu laptop — se você tiver uma H100 sobrando.

⚡ **O que você vai ver hoje:**

- 🦙 Por que Llama 4 é o "Linux da IA" que ninguém pediu para rodar em produção
- 💸 O custo real de "grátis" quando sua equipe gasta 3 meses debugando quantização
- 🎯 O movimento silencioso da Anthropic que já tornou isso irrelevante

CARREIRA & NEGÓCIOS: Open source não paga conta de nuvem

A Meta vazou — ops, "lançou" — o Llama 4 em três tamanhos: 8B, 70B e 405B parâmetros. Benchmarks internos mostram 92% no MMLU, empatando tecnicamente com GPT-4o e Claude 3.5 Sonnet. No papel, é vitória. Na prática, é armadilha.

Rodar o 405B em produção exige 8x H100 (US$ 300k+ só de hardware) ou quantização para 4-bit que derruba performance em 15-20% nas tarefas de raciocínio complexo. Seu time de ML vai virar time de DevOps de inferência. Enquanto isso, a API da Anthropic cobra US$ 3/milhão de tokens de entrada com 99.9% de uptime e zero dor de cabeça.

O "diferencial" da Meta é licença permissiva para uso comercial. Legal. Mas quem já tentou fazer fine-tuning do Llama 3.1 70B sabe: você gasta 2 semanas ajustando LoRA, descobre que o modelo esquece formatação JSON, e volta para a API paga chorando.

> 💡 **O número do jogo:** 73% das empresas que pilotaram Llama 3 em produção migraram de volta para APIs fechadas em 6 meses (fonte: a16z State of AI 2025). A razão não é qualidade do modelo — é custo total de propriedade.

> 🎯 **Recado para a diretoria:** Se seu CTO quer "soberania de dados" rodando Llama 4 on-premise, peça a planilha de TCO incluindo engenheiros sêniores, GPUs, energia e tempo para market. Depois compare com a fatura da Anthropic. A conversa acaba rápido.

Don't Leave, Just Read

- ⚡ **Anthropic lança "Computer Use" estável:** Claude 3.5 Sonnet agora controla mouse e teclado nativamente. Automação de legado sem RPA caro.
- 📦 **DuckDB 1.1 sai com engine vetorial nativo:** Busca semântica em parquet local sem precisar de Pinecone. Finalmente.
- 🛡️ **Google processa Microsoft por patentes de TPU:** Briga de gigantes que não muda sua vida, mas explica por que suas instâncias GCP subiram 12%.

Decifrando na Prática: 3 passos para esta semana

1. **Audite sua stack de LLM:** Liste todos os casos de uso em produção e classifique: "precisa de dados sensíveis on-premise" vs "pode ir para API". Elimine o que for hype.

2. **Teste DuckDB + embeddings locais:** Rode `pip install duckdb` e faça busca semântica nos seus CSVs/Parquets em 15 minutos. Zero infra, zero custo.

3. **Monitore custo por 1k tokens resolvidos:** Não olhe preço de API. Meça quantos tokens você gasta para resolver *um ticket real*. Inclua retries, fallback, validação. Esse é seu KPI.

A Redação Recomenda & Frase do Dia

- **Ferramenta da semana:** [`llama.cpp`](https://github.com/ggerganov/llama.cpp) — ainda a melhor forma de rodar modelos locais sem querer jogar o servidor pela janela.
- *"Open source é como filhote de cachorro: de graça só no começo. Depois vem ração, veterinário e sapato roído."*

MF

Decifrando Dados • por Marlon Ferreira
Ciência de Dados, Machine Learning e Inteligência Artificial na Prática

linkedin.com/newsletters/decifrando-dados-7513791689808064512/