D Decifrando Dados

EDIÇÃO 26

Por **Marlon Ferreira**

11/10/2026 • Leitura: 4 min

O Cemitério dos Petabytes: Por que as Empresas Gastam Milhões em Dados de TI (e Continuam Cegas nas Quedas)

Faturas de seis dígitos no Datadog, 85% de logs nunca lidos e o mito do AIOps: como a telemetria corporativa virou o maior ralo financeiro da nuvem

Efeméride: Há 15 anos na tecnologia…

Em agosto de 2011, o investidor Marc Andreessen publicou seu famoso ensaio no The Wall Street Journal com a frase que virou mantra corporativo: *"Why Software Is Eating the World"*. O que o fundador da Netscape não previu naquele artigo foi a linha miúda da fatura: quinze anos depois, seriam os logs desse mesmo software que estariam comendo, sem cerimônia, o orçamento de tecnologia das empresas.

Naquela época, monitorar infraestrutura era uma rotina quase monástica. O administrador de sistemas configurava um servidor Nagios com tela cinza, torcia para os e-mails de alerta não caírem na caixa de spam e usava `grep` e `tail -f` diretamente no arquivo `/var/log/syslog`. Se o disco rígido ameaçasse lotar durante a madrugada, o procedimento padrão era abrir uma sessão SSH no servidor de produção e executar `cat /dev/null > error.log`. O ecossistema era rudimentar, mas todo mundo sabia exatamente o que estava quebrado. Até que alguém decidiu quebrar a aplicação em duzentos microsserviços.

⚡ O que você vai ver hoje

- 🗑️ **O lixo mais caro do mundo:** Por que 85% dos dados de telemetria corporativa são deletados sem que nenhum humano ou algoritmo chegue a ler.
- 💸 **O choque do fim de semana:** Como um único loop de debug em produção pode emitir terabytes de ruído e faturar US$ 60 mil na nuvem.
- 🤖 **O blefe do AIOps milagroso:** Por que alimentar modelos de linguagem com pilhas de logs desestruturados gera apenas alucinações caras.
- 🧉 **Don't Leave, Just Read:** Giro expresso com CrowdStrike, a migração para ClickHouse, o padrão eBPF e a fadiga operacional.

- 🛠️ **Decifrando na Prática:** 3 decisões técnicas de arquitetura para implementar amostragem inteligente e derrubar os custos de telemetria.

INFRAESTRUTURA & NEGÓCIOS ÁGEIS

O Cemitério dos Petabytes: A ilusão da observabilidade total e o ralo financeiro dos dados de TI

Toda organização moderna se autoproclama orientada a dados quando o assunto é funil de vendas, retenção de clientes ou previsão de faturamento. Painéis executivos exigem governança impecável, catálogos refinados e modelagem dimensional precisa. No entanto, quando cruzamos a fronteira e entramos no território dos dados de TI (logs, métricas, traces e telemetria de redes), a postura corporativa regride para a Idade da Pedra: coleta-se absolutamente tudo, armazena-se de forma caótica e torce-se para que ninguém audite a conta no final do mês.

A ascensão dos clusters de Kubernetes e das arquiteturas distribuídas transformou uma simples operação de compra em uma cascata de cinquenta chamadas remotas. Cada componente dessa esteira emite centenas de registros por segundo, a maioria preenchida com puro ruído operacional: pings de health check, confirmações repetidas de autenticação e avisos rotineiros de `HTTP 200 OK`.

O modelo de negócios das ferramentas tradicionais de monitoramento agradece. Ao cobrar diretamente pelo volume de gigabytes ingeridos, indexados e armazenados, provedores de observabilidade criaram uma armadilha financeira perfeita. Toda equipe de engenharia tem uma história de horror para contar: o deploy inocente de sexta-feira em que uma linha de código contendo `logger.debug(full_request_payload)` passou despercebida no code review e produziu uma fatura surpresa de US$ 50 mil em apenas quarenta e oito horas.

> 💡 **O número do jogo:** Segundo levantamentos consolidados da Enterprise Management Associates (EMA) e do Gartner, entre 80% e 85% de toda a telemetria corporativa coletada e paga nunca é consultada por nenhum operador ou algoritmo antes de expirar na janela de retenção de trinta dias. Ao mesmo tempo, 71% das quedas graves de sistemas ainda são reportadas primeiro por clientes furiosos nas redes sociais ou no canal de suporte, e não pelos alarmes automatizados da empresa.

Para piorar o cenário, o mercado agora vende o milagre do "AIOps": a promessa de plugar modelos de inteligência artificial generativa sobre esse lixão digital para sintetizar causas-raiz de falhas. Na prática, a matemática não fecha. Modelos de linguagem operando sobre montanhas de logs desestruturados consomem quantidades monumentais de tokens para produzir relatórios genéricos ou alucinar correlações inexistentes entre eventos desconexos. Se o dado de entrada é ruído sujo, o agente de IA vira apenas um gerador de desculpas automatizado e faturado por minuto.

> 🎯 **Recado para a diretoria:** Acumular petabytes de dados de infraestrutura não torna a sua operação resiliente; apenas torna a sua conta de nuvem indefensável. Observabilidade inteligente não consiste em sugar cada pacote emitido pela rede, mas em projetar consultas que respondam com clareza aos impactos reais no cliente. Se a sua empresa gasta mais com ingestão de telemetria do que com o desenvolvimento do produto principal, você não tem um ambiente monitorado; tem um ralo financeiro institucionalizado.

🧉 Don't Leave, Just Read

- 🟢 **CrowdStrike e a telemetria fora da caixa:** Meses após o incidente que travou 8,5 milhões de máquinas com tela azul pelo mundo, a comunidade técnica aprendeu que depender exclusivamente de agentes rodando dentro do sistema operacional cria pontos cegos fatais. A nova prioridade de infraestrutura é o monitoramento sintético externo e verificações independentes de integridade pré-boot.
- 🟡 **A debandada para ClickHouse e VictoriaLogs:** Pressionadas por orçamentos enxutos, empresas de alta tecnologia estão trocando contratos SaaS milionários de observabilidade por bancos colunares de código aberto. A combinação de OpenTelemetry com ClickHouse tem entregado reduções de até 75% na despesa de retenção de logs sem comprometer a agilidade nas investigações.
- 🔵 **O avanço silencioso do eBPF no Linux:** A necessidade de embutir bibliotecas pesadas de rastreamento dentro do código das aplicações está sendo superada pelo eBPF. A tecnologia opera diretamente no kernel do Linux, capturando métricas de tráfego, consumo e segurança com impacto inferior a 1% na CPU e sem injetar código invasivo nos microsserviços.
- 🔴 **Fadiga de alertas atinge 62% dos engenheiros:** Levantamento recente sobre rotina operacional indicou que mais de 60% dos profissionais de confiabilidade (SRE) admitem silenciar ou ignorar notificações automáticas de média prioridade. O excesso de alertas mal calibrados transformou canais de emergência em caixas de entrada abandonadas.

🛠️ Decifrando na Prática

Reduzir o custo com dados de TI sem perder visibilidade técnica exige disciplina arquitetural e filtros rigorosos na origem:

- **1. Amostragem seletiva na borda com OpenTelemetry Collector:** Em vez de transmitir cada transação rotineira para o provedor de observabilidade, implemente filtros de amostragem probabilística (tail-based sampling) nos coletores locais. Descarte 99% das requisições bem-sucedidas com código `200 OK` e mantenha 100% dos traces que apresentarem erros `5xx` ou tempos de resposta acima do percentil P95.

- **2. Esquemas de log estritamente estruturados em JSON:** Elimine o uso de strings livres de texto puro em arquivos de log. Padronize um formato JSON contendo campos determinísticos como `service_name`, `trace_id`, `tenant_id`, `http_status` e `duration_ms`. Isso viabiliza indexação colunar de baixo custo e elimina consultas pesadas com expressões regulares que consomem horas de processamento.
- **3. Arquitetura de retenção em camadas (Hot vs. Cold Storage):** Limite a retenção em discos de altíssima performance para no máximo sete dias, período em que ocorrem 95% das investigações de incidentes. Dados exigidos para conformidade ou auditoria de segurança devem ser convertidos em arquivos colunares Parquet com compressão ZSTD e armazenados em buckets de baixo custo (S3 ou GCS), prontos para consultas sob demanda via DuckDB ou Athena.

💡 A Redação Recomenda & Frase do Dia

- **A Redação Recomenda:** Conheça e avalie o projeto open source **Vector** (mantido pela Datadog, mas 100% aberto e escrito em Rust). Ele funciona como um roteador de telemetria ultra-leve e de altíssima vazão, permitindo transformar, validar e filtrar dados de infraestrutura antes que eles cheguem aos destinos comerciais pagos.
- **Frase do Dia:** *"Se você precisa ler dezenas de arquivos de log para descobrir por que a aplicação caiu, você não tem um sistema de observabilidade; você tem um mistério investigativo cobrado por hora de consultoria."* — Charity Majors, cofundadora da Honeycomb e pioneira em engenharia de observabilidade.

MF

Decifrando Dados • por Marlon Ferreira
Ciência de Dados, Machine Learning e Inteligência Artificial na Prática
linkedin.com/newsletters/decifrando-dados-7513791689808064512/